

REPORTE E INSIGHTS SOBRE EL EDA

—


CIENCIA DE DATOS EN PRODUCCIÓN

Pablo Buitrago Álvarez



Pasos seguidos

—



1. Numéricas

1.1. Discretas

- edad_cliente
- plazo_meses
- total_otros_prestamos
- cant_creditosvigentes
- creditos_sectorFinanciero
- creditos_sectorCooperativo
- creditos_sectorReal
- huella_consulta

1.2. Continuas

- capital_prestado
- salario_cliente
- cuota_pactada
- puntaje
- puntaje_datacredito
- saldo_mora
- saldo_total
- saldo_principal
- saldo_mora_codeudor
- promedio_ingresos_datacredito

2. Categóricas

2.1. Politómicas

- tipo_credito
- tendencia_ingresos

2.2. Dicotómicas

- tipo_laboral
- pago_atiempo (TARGET)

3. Otras

- 3.1. FECHA: fecha_prestamo

Datos Generales

DUPLICADOS

El dataset tiene 0 duplicados




DIMENSIONES

Cantidad de Registros:
aproximadamente
10763

Variables o columnas:
inicialmente 23

CONTEO DE NULOS



tendencia_ingresos	2990
promedio_ingresos_datacredito	2930
saldo_mora_codeudor	590
saldo_principal	405
saldo_mora	156
saldo_total	156
puntaje_datacredito	6

SOBRE LOS DATOS Y SUS ESTADÍSTICAS

	Columna	Kurtosis	Skew-Sesgo
0	capital_prestado	35.301130	3.723365
1	plazo_meses	7.775949	2.459348
2	edad_cliente	7.864723	1.934129
3	salario_cliente	2210.202459	43.770563
4	total_otros_prestamos	1718.481718	38.458525
5	cuota_pactada	26.637820	3.792772
6	puntaje	24.069268	-4.864929
7	puntaje_datacredito	39.418912	-5.643726
8	cant_creditosvigentes	8.618783	1.797487
9	huella_consulta	3.996569	1.486895
10	saldo_mora	1844.842312	40.562746
11	saldo_total	788.794183	20.194818
12	saldo_principal	51.038614	5.049440
13	saldo_mora_codeudor	9275.263891	94.957500
14	creditos_sectorFinanciero	19.432183	2.702694
15	creditos_sectorCooperativo	29.337264	4.218079
16	creditos_sectorReal	18.178203	3.164425
17	promedio_ingresos_datacredito	32.749068	4.279331

salario_cliente, total_otros_prestamos, saldo_mora, saldo_mora_codeudor son las variables con los sesgos más grandes.

Los datos no siguen una curva normal porque presentan valores atípicos muy extremos.

Muchos datos se concentran en un mismo rango de valores (“lo normal”) y pocos valores en los extremos (“los atípicos”).

Variables con sesgo negativo son **puntaje** y **puntaje_datacredito**, esto es el reflejo del sistema financiero. Personas con préstamos con buen historial son comunes pero hay uno pocos con puntajes pauperrimos.

Variables levemente asimétricas, están **capital_prestado**, **plazo_meses** y **cuota_pactada** que se deriva en parte del capital prestado → Mayoría montos pequeños y de pequeño plazo.

PRUEBA CON DIST. NORMAL

Ninguna variable sigue una distribución normal, conformando el análisis de curtosis y sesgos.

PRUEBA CON DIST. GAMMA/EXPONENCIAL

Tampoco se ajustan a estas 2 distribuciones, a pesar de que simulan mejor los saltos y las colas pesadas.

PRUEBA CON DIST. LOG-NORMAL



Los datos no siguen una distribución log-normal.

CASOS "ESPECIALES"

capital_prestado: 0.0119 y **cuota_pactada:** 0.009 tienen p-values cercanos al 1%

Test de Kolmogorov-Smirnov

- Nunca usar el promedio para tomar decisiones.
- Mejorar modelos de riesgos.



- Las diferencias entre cuotas no son aditivas, son proporcionales. La variación ocurre en porcentajes, no en montos fijos

¿PROBLEMAS DE CALIDAD DE DATOS?

- En **edad_cliente**, más de 150 registros están por encima de 100 años.
- La gran mayoría de personas en **cant_creditosvigentes** (99%) se encuentran entre 0 y 10 créditos. Sucede igual en créditos del sector real, financiero y cooperativo.
- Análisis cruzado: **total_otros_prestamos**, al revisar los individuos en los percentiles superiores observamos que existe una correspondencia entre un valor alto en esta columna junto con el **salario_cliente** → Es lógico.
- Análisis cruzado: Al revisar los individuos con mayor cantidad de créditos en el sector financiero, se observa que el valor que se debe no supera las **10-15 veces su salario**.
- El **puntaje_datacredito** va desde los 150 hasta 950 → Esta es una regla establecida por la Ley 1266 de 2008 (Habeas Data).

“No solo para estas variables sino apoyándonos en los conceptos previos y pruebas estadísticas hechas anteriormente, no es factible eliminar y poner en Null los registros que se salgan del IQR o de una distribución teórica o que se entrada se vean muy raros”.

EN GENERAL SOBRE LAS NUMÉRICAS

Los gráficos de densidad con la curva normal teórica muestran el resultado de los p-values del test. Los datos **no siguen una distribución normal, los datos atípicos desvían y amplían esa distancia entre las 2 curvas**. La diferencia entre algunas varias se evidencia en el sesgo y el desplazamiento de la distribución.

CASOS PARTICULARES

capital_prestado y **cuota_pactada** presentan un sesgo hacia la derecha, significa que la mayoría de los créditos son por montos bajos y existen pocos montos altísimos que hacen que se presente la curtosis alta.

SOBRE LA CANTIDAD DE CRÉDITOS

Las personas comunmente tienen pocos préstamos en su vida o por lo menos no acumulan varios al mismo tiempo (**creditos_sectorFinanciero, creditos_sectorCooperativo, creditos_sectorReal**)


CONCENTRACIÓN DE PRODUCTOS DE CRÉDITO

La categoría 4 concentra casi el 74% , seguida por el tipo 9 con un 25%.

LA OBJETIVO DESBALANCEADA

Desbalanceo de clases → el 95% de los registros corresponden a clientes que pagaron a tiempo y el resto son morosos

Si se parten las variables numéricas en intervalos → con 1 o 2 intervalos basatría para agrupar los valores.






```
Columna: tipo_credito
tipo_credito
4      7747
9      2876
10     116
6        21
7         2
68         1
Name: count, dtype: int64

Columna: tipo_laboral
tipo_laboral
Empleado      6754
Independiente  4009
Name: count, dtype: int64



Columna: tendencia_ingresos
tendencia_ingresos
Creciente      5294
NaN            2990
Decreciente    1291
Estable         1188
Name: count, dtype: int64

Columna: Pago_atiempo
...
Si      10252
No        511
Name: count, dtype: int64
```








La variable **puntaje** que es una métrica interna. Se ve la divergencia entre las personas que son morosas y las que no: los morosos tienen puntajes bajos, aproximadamente entre 0 y 60; por otro lado, el puntaje de las personas que pagan, tiene como limite inferior 60 y se extiende hasta 100 (cerca a 100 se encuentra la mayoría de registros que cumplen con el pago).



El **saldo_total** de las personas que cumplen con los compromisos del crédito suele ser más alto que de las personas que no. Puede estar relacionado con el salario y las condiciones de asignación.



No es posible discriminar por tipo de crédito si una persona paga a tiempo o no en función del plazo del préstamo.

El tipo de producto financiero → el tipo 4 para empleados y el tipo y el tipo 9 para independientes.

Productos masivos vs de nicho → el tipo 4 se solicita en jóvenes y baja en los más adultos. El tipo 9 es comporta a la inversa.

VARIABLES DERIVADAS

- DTI
- APALANCAMIENTO
- EXPOSICIÓN POR PUNTO
- INTENSIDAD DE CRÉDITO

DTI = Cuota Pactada / Salario Cliente → Debt to Income Ratio

Indica el porcentaje de los ingresos comprometidos para el crédito asignado. DTI bajo indica que el cliente tiene una carga de deuda menor.

Apalancamiento = (Capital Prestado + Total Otros Prestamos) / Salario Cliente












Mide la proporción de la deuda total en relación con el salario. Una medida alta indica que el cliente tiene una mayor carga en relación a los ingresos.

Exposición por Punto = Capital Prestado / Puntaje Datacrédito


Mide cuánto capital está prestado por cada punto del puntaje de crédito del cliente. Un valor más alto de exposición por punto puede indicar un mayor riesgo

Intensidad Crediticia = Cantidad Creditos Vigentes / Edad Cliente

Mide la cantidad de créditos vigentes con la edad. Un valor más alto de intensidad de crédito puede indicar un mayor riesgo, ya que el cliente tiene más créditos activos en relación con su edad



ANÁLISIS MULTIVARIABLE



cuota_pactada y capital_prestado -
Correlación: 0.76


saldo_principal y saldo_total -
Correlación: 0.73

creditos_sectorFinanciero y cant_creditosvigentes -
Correlación: 0.79

exposicion_por_punto y cuota_pactada -
Correlación: 0.72

Pago_atiempo_num y puntaje -
Correlación: 0.92

MUTUAL INFORMATION



El **puntaje** es la variable más importante para predecir el pago a tiempo, con un MI de 0.17, lo que indica que tiene una relación significativa con la variable objetivo.

La **tendencia de ingresos** también es relevante, con un MI de 0.05, lo que sugiere que el comportamiento de los ingresos del cliente puede influir en su capacidad para pagar a tiempo.

ANOTACIONES FINALES

fecha_prestamo → podría eliminarse al no ser un ejercicio de series de tiempo.

saldo_principal y **saldo_total** tienen una correlación alta → Se puede eliminar una.

DTI y **Apalancamiento** son redundantes → Su alta correlación indica que podemos eliminar una.

saldo_mora_codeudor tiene una ganancia muy poca con la objetivo, se puede considerar eliminar.

En la variable **tipo_credito** se puede plantear la eliminación de las clases con menor frecuencia, agruparlas como "Otros" y dejar tpo 4 y tipo 9.

La variable **plazo_meses** podría discretizarse por intervalos con el fin de facilitar el análisis.

```
variables_a_eliminar = ['fecha_prestamo', 'creditos_sectorCooperativo', 'creditos_sectorReal',  
                        'creditos_sectorFinanciero', 'saldo_principal', 'dti', 'saldo_mora_codeudor']
```

**MUCHAS
GRACIAS**

—